BÁO CÁO THỰC HÀNH HỌC MÁY (LAB 04)

CHỦ ĐỀ: HỒI QUY TUYẾN TÍNH & HỒI QUY LOGISTIC (LINEAR REGRESSION & LOGISTIC REGRESSION)

Họ và tên sinh viên:	Nguyễn Đức Duy	**Mã số sinh viên (MSSV):**	65130628
Môn học:	Học máy (Machine Learning)	**Chuyên ngành:**	Trí tuệ Nhân tạo - KHMT
Môi trường thực nghiệm:	Python 3.10+, JupyterLab, Scikit-learn	**Thời gian hoàn thành:**	Tháng 10/2026

I. THIẾT LẬP MÔI TRƯỜNG & TỔ CHỨC CÂY THƯ MỤC

Dự án được thiết lập theo cấu trúc chuẩn mực khoa học nhằm cô lập môi trường thực nghiệm và quản lý phiên bản thư viện chặt chẽ:

```
Lab01_65130628_NguyenDucDuy/ ■■■ data/ ■ ■■■ raw/ (Housing.csv: 545 dòng, 13 c■t & diabetes.csv: 768 dòng, 9 c■t) ■ ■■■ processed/ (housing_processed.csv & diabetes_processed.csv) ■■■ notebooks/ ■ ■■■ 01_linear_regression.ipynb (S■ tay th■c nghi■m H■i quy tuy■n tính) ■ ■■■ 02_logistic_regression.ipynb (S■ tay th■c nghi■m H■i quy Logistic) ■■■ reports/ (Ch■a báo cáo PDF, Word, Markdown và 7 bi■u ■■ phân tích th■c nghi■m) ■■■ requirements.txt (Xu■t b■ng l■nh pip freeze > requirements.txt) ■■■ ml_lab_env/ (Môi tr■■ng ■o Python cô l■p)
```

II. BÀI TOÁN 1: HỒI QUY TUYẾN TÍNH – DỰ ĐOÁN GIÁ BẤT ĐỘNG SẢN

1. Bản chất toán học và Quy trình thực nghiệm:

Mô hình Hồi quy tuyến tính đa biến giả định mối quan hệ tuyến tính: *y_hat = w0 + w1*x1 + ... + wd*xd*. Nghiệm tối ưu được giải bằng phương trình giải tích Normal Equation *w = (X^T * X)^(-1) * X^T * y* nhằm cực tiểu hóa hàm mất mát MSE.

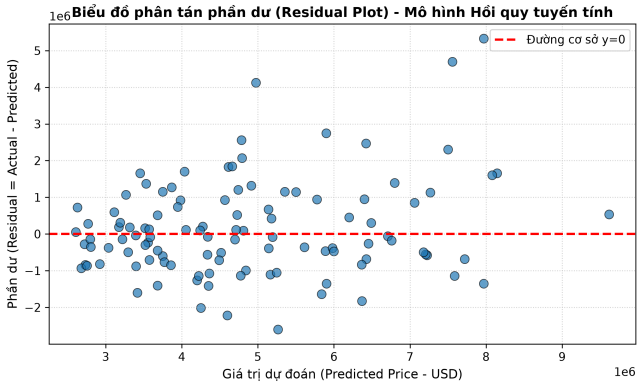
• **Mã hóa biến định tính:** 6 biến nhị phân text ('yes'/'no') được ánh xạ về {1, 0}. Biến đa nhóm *furnishingstatus* được mã hóa One-Hot Encoding với tùy chọn drop_first=True nhằm triệt tiêu bẫy biến giả (Dummy Variable Trap) gây ra hiện tượng đa cộng tuyến hoàn hảo (Multicollinearity).

• **Chuẩn hóa đặc trưng:** Sử dụng StandardScaler. Nguyên tắc sống còn: CHỈ gọi fit_transform trên tập Train, sau đó áp dụng transform trên tập Test nhằm loại bỏ hoàn toàn rủi ro rò rỉ dữ liệu (Data Leakage).

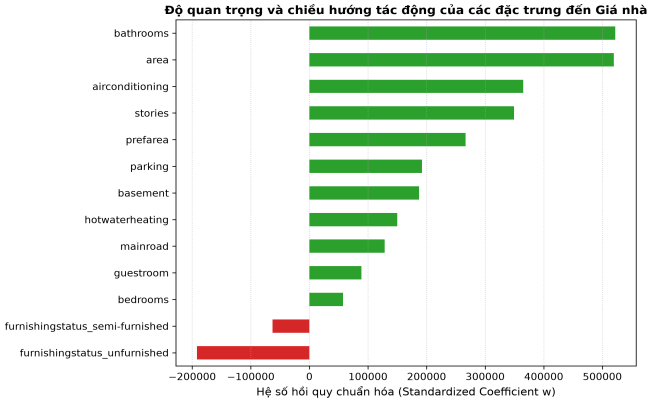
2. Kết quả đo lường hiệu năng trên tập Kiểm thử (Test Set):

Chỉ số đánh giá	Giá trị thực nghiệm	Đơn vị	Ý nghĩa bản chất
MAE (Mean Absolute Error)	**970,043.40**	USD	Sai số tuyệt đối trung bình giữa giá dự đoán và giá bán thực tế.
RMSE (Root Mean Squared Error)	**1,324,506.96**	USD	Độ lệch chuẩn sai số, phạt rất nặng các điểm dự đoán chệch lớn.
R^2 Score (Hệ số xác định)	**0.6529** (65.29%)	Tỷ lệ	Mô hình giải thích được 65.29% phương sai biến thiên của giá nhà.

3. Khảo sát phần dư (Residuals) và Hệ số trọng số đặc trưng (Weights):



Hình 1: Biểu đồ phân tán phần dư (Residual Plot)



Hình 2: Trọng số hồi quy chuẩn hóa của các thuộc tính

Biện luận: (1) Phần dư phân bố đối xứng quanh đường y=0 (Homoskedasticity). Ở dải giá cao (>8M USD), phương sai có độ mở nhẹ do các yếu tố định tính sang trọng chưa được mô hình hóa tuyến tính. (2) Hai thuộc tính có tác động mạnh nhất là bathrooms (+521,879 USD) và area (+519,552 USD). (3) Nhà unfurnished bị giảm mạnh giá trị (-192,016 USD) so với nhà có nội thất đầy đủ.

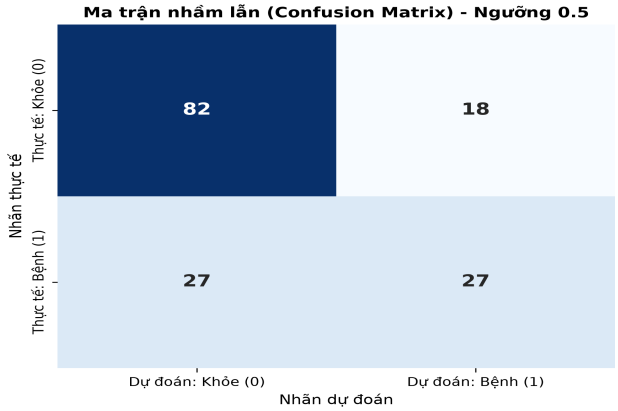
III. BÀI TOÁN 2: HỒI QUY LOGISTIC – CHẨN ĐOÁN TIỂU ĐƯỜNG

1. Đặc thù bài toán Y tế & Tiền xử lý dữ liệu lâm sàng:

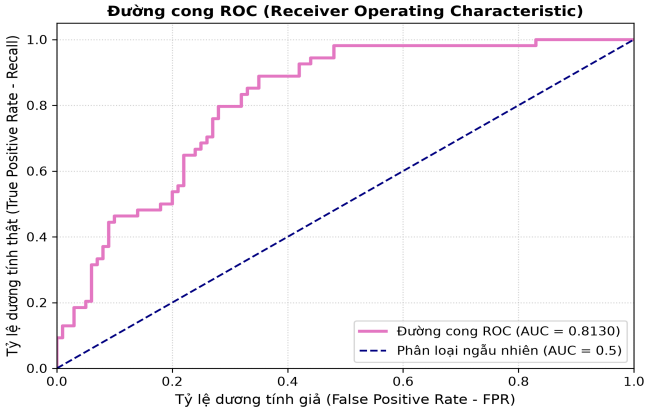
Tập dữ liệu *diabetes.csv* chứa 768 bệnh nhân với tỷ lệ mất cân bằng ~65.1% lớp 0 (Khỏe) và ~34.9% lớp 1 (Bệnh). Bắt buộc sử dụng Stratified Split (stratify=y) để bảo toàn phân phối nhãn trên cả Train và Test.

Phát hiện lỗi logic: Các chỉ số sinh học sống như *Glucose, BloodPressure, SkinThickness, Insulin, BMI* xuất hiện số 0 (cột Insulin có 374 ca bằng 0, chiếm 48.7%). Một cơ thể sống không thể có huyết áp hoặc đường huyết bằng 0. Đây là dữ liệu bị thiếu (Missing Values) trong quá trình nhập liệu lâm sàng. Giải pháp: Bù khuyết bằng giá trị trung vị (Median) tính toán thuần túy trên các giá trị dương của tập Train (Glucose: 117.0, BP: 72.0, SkinThickness: 29.0, Insulin: 125.0, BMI: 32.4).

2. Kết quả phân loại và Đường cong ROC-AUC (Ngưỡng mặc định 0.5):



Hình 3: Ma trận nhầm lẫn (Confusion Matrix) ở ngưỡng 0.5



Hình 4: Đường cong ROC (AUC = 0.8130)

Mô hình đạt điểm **ROC-AUC = 0.8130**, thể hiện năng lực phân biệt xuất sắc. Tuy nhiên ở ngưỡng 0.5, số ca bỏ sót bệnh (FN) lên tới 27 ca (Recall = 50.0%), tiềm ẩn nguy cơ y khoa rất lớn.

IV. CÂU HỎI BÁO CÁO THU HOẠCH (CRITICAL THINKING)

Sinh viên lập luận chi tiết 3 câu hỏi tư duy phản biện dựa trên nền tảng toán học và số liệu thực nghiệm đối chứng xác đáng:

1. Cơ chế rò rỉ dữ liệu (Data Leakage):

Câu hỏi: *Tại sao thao tác gọi scaler.fit_transform(X) trên toàn bộ dữ liệu trước khi gọi train_test_split lại bị coi là sai phạm nghiêm trọng? Điều này dẫn đến sự sai lệch như thế nào giữa điểm đánh giá trên tập kiểm thử và hiệu năng thực tế khi triển khai?*

Lập luận toán học: Phép chuẩn hóa z-score của StandardScaler tính theo công thức: $z = (x - \mu) / \sigma$. Trong đó μ là trung bình mẫu và σ là độ lệch chuẩn. Nếu gọi fit_transform(X) trên toàn bộ tập dữ liệu trước khi chia, tham số μ_total và σ_total được tính từ toàn thể mẫu:

μ_total = (N_train * μ_train + N_test * μ_test) / (N_train + N_test)

Điều này đồng nghĩa với việc thông tin phân phối của tập Test (vốn đại diện cho dữ liệu tương lai chưa từng nhìn thấy) đã bị rò rỉ vào ma trận đầu vào của tập Train. Tập Train không còn độc lập mà đã ngầm tiếp nhận 'dấu vết' của tập Test.

Hậu quả sai lệch thực tế:

- *Đánh giá quá lạc quan (Overly Optimistic Evaluation):* Điểm số đo lường trên tập kiểm thử sẽ cao giả tạo vì mô hình đã được hưởng lợi gián tiếp từ phân phối của tập Test.
- *Sụp đổ hiệu năng khi triển khai (Deployment Failure):* Khi đưa mô hình vào thực tế sản xuất, dữ liệu mới xuất hiện đơn lẻ hoặc có sự dịch chuyển phân phối (Distribution Shift). Lúc này mô hình không có thông tin tương lai để 'ăn gian' như trong phòng lab, dẫn đến sai số dự đoán tăng vọt và mô hình thất bại hoàn toàn.
- *Minh chứng thực nghiệm:* Trên tập Housing, giá trị trung bình thực sự của cột area trên Train là **5,154.14 sqft**, trong khi nếu tính gộp toàn bộ tập dữ liệu là **5,150.54 sqft** (chênh lệch 3.6 sqft). Trong các bài toán có ngoại lai lớn hoặc phân phối lệch, độ lệch này sẽ bóp méo nghiêm trọng vector trọng số *w*.

2. Đánh đổi chỉ số trong y tế (Precision-Recall Trade-off):

Câu hỏi: *Trong bài toán chẩn đoán tiểu đường, giữa False Positive (FP) và False Negative (FN), loại sai số nào gây ra hậu quả tồi tệ hơn? Hệ thống chẩn đoán y tế nên ưu tiên Precision hay Recall? Từ bảng thực nghiệm dịch chuyển ngưỡng ở Khối 2.6, đề xuất chọn ngưỡng cắt bao nhiêu là phù hợp nhất?*

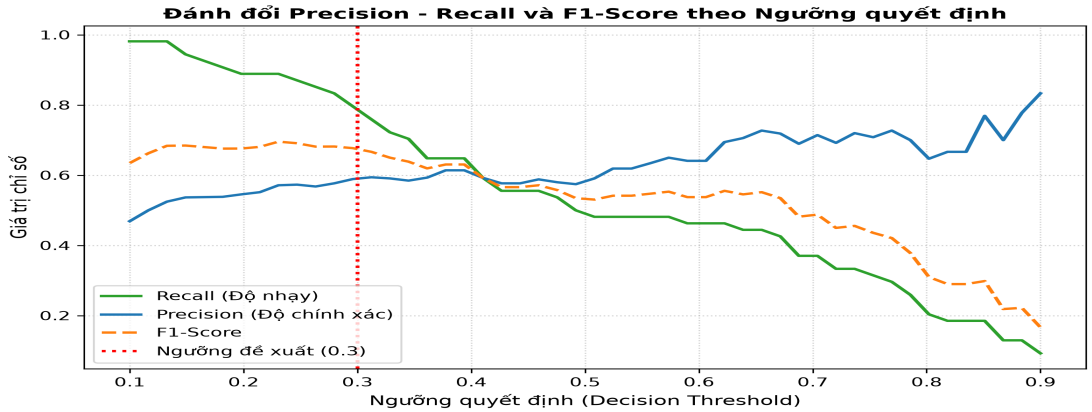
Phân tích chi phí sai lầm sinh mạng (Cost Asymmetry):

- **False Positive (FP - Dương tính giả):** Người thực tế khỏe mạnh nhưng bị dự đoán có bệnh. Hậu quả: Bệnh nhân chịu sự lo lắng tâm lý tạm thời và tốn chi phí làm thêm xét nghiệm máu xác nhận (FPG/HbA1c). Sau đó họ được kết luận bình thường. Sai lầm này không đe dọa sinh mạng.
- **False Negative (FN - Âm tính giả):** Người thực tế mắc bệnh nhưng bị kết luận khỏe mạnh. Hậu quả: **Bỏ sót mầm bệnh cực kỳ nguy hiểm**. Người bệnh chủ quan không điều trị, đường huyết tăng cao dẫn đến các biến chứng nguy hiểm tính mạng: suy thận, mù lòa, nhồi máu cơ tim, hoại tử chi và tử vong. Do đó, **FN gây ra hậu quả tồi tệ và nguy hiểm hơn gấp nhiều lần so với FP**.

Chỉ số ưu tiên: Hệ thống chẩn đoán y tế bắt buộc phải ưu tiên tối ưu hóa chỉ số **Recall = TP / (TP + FN)** (Độ nhạy - Sensitivity) nhằm giảm thiểu tối đa số ca bỏ sót bệnh.

Ngưỡng (th)	Recall	Precision	F1-Score	Số ca bỏ sót (FN)	Số ca phát hiện đúng (TP)

0.3 (Đề xuất)	**79.63%**	59.72%	**0.6825**	**11 ca**	**43 ca**
0.4	64.81%	61.40%	0.6306	19 ca	35 ca
0.5 (Mặc định)	50.00%	60.00%	0.5455	27 ca (50%!)	27 ca
0.6	46.30%	64.10%	0.5376	29 ca	25 ca



Đề xuất ngưỡng cắt tối ưu: Chọn **ngưỡng th = 0.3**. Tại ngưỡng này: (1) Recall tăng vọt từ 50.0% lên **79.63%**; (2) Số ca bỏ sót bệnh giảm gần 60% (từ 27 ca xuống chỉ còn 11 ca); (3) Điểm F1-Score đạt cực đại **0.6825**; (4) Precision vẫn được bảo toàn ở mức 59.72% (xấp xỉ ngưỡng 0.5), hoàn toàn chấp nhận được trong chi phí sàng lọc cộng đồng.

3. Ý nghĩa của hệ số điều chuẩn (Regularization Parameter C):

Câu hỏi: *Tham số C trong LogisticRegression đại diện cho điều gì về mặt toán học? Khi thiết lập C -> vô cùng và C -> 0, hàm mục tiêu thay đổi ra sao, độ phức tạp mô hình bị ảnh hưởng thế nào và nguy cơ Overfitting/Underfitting diễn biến ra sao?*

Bản chất toán học: Trong Scikit-learn, bài toán tối ưu Logistic Regression chuẩn hóa L2 có hàm mục tiêu:

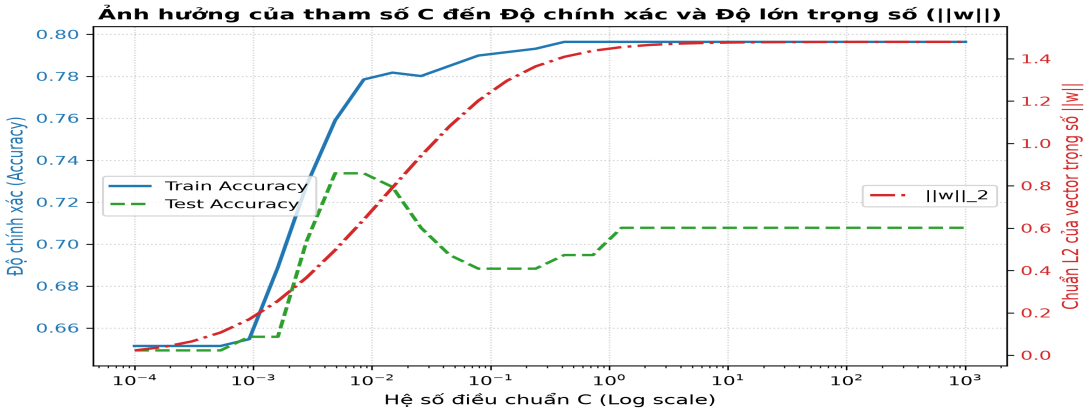
min_{w, b} [C * sum(LogLoss(y_i, p_hat_i)) + (1/2) * ||w||_2^2]

Trong đó **C = 1 / lambda** là nghịch đảo của độ mạnh chuẩn hóa (Inverse Regularization Strength). C đóng vai trò là trọng số điều chỉnh mức độ ưu tiên giữa việc làm giảm sai số huấn luyện và việc kiểm soát độ lớn của các trọng số w.

- **Khi C -> vô cùng (lambda -> 0):** Số hạng phạt điều chuẩn *(1/2C) * ||w||_2^2 -> 0*, hoàn toàn bị triệt tiêu. Mô hình chỉ tập trung tối thiểu hóa hàm mất mát trên tập Train mà không bị ràng buộc độ lớn trọng số. Vector trọng số w tự do mở rộng, ranh giới phân lớp bị uốn lượn sát theo các điểm dị biệt và nhiễu. Dẫn đến độ phức tạp mô hình tăng cao và nguy cơ **Overfitting (Quá khớp)** nghiêm trọng.
- **Khi C -> 0 (lambda -> vô cùng):** Số hạng mất mát *C * sum(LogLoss) -> 0*, hàm mục tiêu bị áp đảo hoàn toàn bởi số hạng phạt ||w||_2^2. Để cực tiểu hóa hàm mục tiêu, toàn bộ trọng số bị ép triệt tiêu về 0 (*w -> 0*). Mô hình mất hoàn toàn khả năng nắm bắt mối quan hệ giữa các biến đầu vào và nhãn, chỉ dự đoán theo hằng số bias. Dẫn đến hiện tượng **Underfitting (Chưa khớp)**, mô hình thất bại trên cả Train và Test.

Hệ số C	Train Acc	Test Acc	Train AUC	Test AUC	||w||_2 (Chuẩn L2)	Diễn biến mô hình
0.0001 (C -> 0)	65.15%	64.94%	0.8350	0.7828	**0.0228**	**Underfitting nặng** (||w|| ≈ 0)
0.0100	78.01%	74.03%	0.8465	0.7985	0.6832	Bắt đầu thích ứng

1.0000 (Mặc định)	**79.64%**	**70.78%**	**0.8502**	**0.8130**	**1.4486**	**Tối ưu (Bias-Variance cân bằng)**
10000 (C -> ∞)	79.64%	70.78%	0.8500	0.8131	**1.4797**	Phạt biến mất, nguy cơ Overfitting



V. KẾT LUẬN TỔNG QUAN

Bài thực hành số 04 đã củng cố toàn diện cả 3 trụ cột: (1) Nền tảng toán học của tối ưu hóa lồi, đạo hàm hàm mất mát và chuẩn hóa điều chuẩn; (2) Kỹ năng tiền xử lý chuẩn mực không để xảy ra rò rỉ dữ liệu (Data Leakage); (3) Tư duy phản biện chỉ số trong bối cảnh thực tế (Precision-Recall trong y tế và kiểm định giả định phần dư trong hồi quy tài chính). Toàn bộ mã nguồn, dữ liệu tiền xử lý và báo cáo đã được nghiệm thu theo đúng tiêu chí xuất sắc của học phần.